CS285 深度强化学习与模仿学习学习笔记

从 Reinforcement Learning 到 Behavioral Cloning、DAgger、Diffusion Policy

面向零基础的中文 LaTeX 版笔记

2026 年 6 月 2 日

资料来源与使用说明

本笔记综合了用户提供的 Berkeley CS 185/285 课件 `lec-1.pdf`、`lec-2.pdf`、`lec-3.pdf`，以及用户给出的知乎文章题目“强化学习 *CS285* 笔记【一】*Behaviour Clone*（为什么要用强化学习）”和 B 站 CS285 视频信息。知乎原文在网页抓取时存在 403 访问限制，因此本文主要以课件内容、课程公开视频结构、公开视频/转写页面可见信息为主，补充了更适合新手的推导、直觉解释与公式整理。

目录

1 先给新手的一句话总览 **4**

1.1 这三节课的主线 4

2 基本符号：先把“状态、动作、奖励”说清楚 **5**

2.1 Agent 与 Environment 5

2.2 Fully Observed 与 Partially Observed 7

2.3 Markov Property：为什么只看当前状态就够？ 7

3 从监督学习到模仿学习：Behavioral Cloning **8**

3.1 监督学习的最大似然写法 8

3.2 把“模仿专家”变成监督学习 8

3.3 Behavioral Cloning 算法流程 9

3.4 离散动作与连续动作 10

3.4.1 离散动作：输出 logits 10

3.4.2 连续动作：输出高斯分布参数 10

4 为什么 Behavioral Cloning 会失败：Distributional Shift 11
4.1 监督学习默认 i.i.d.，但控制问题不是 . . . 11
4.2 小错误为什么会越滚越大？ . . . 12

5 理论推导：BC 的误差为什么可能是 $O(T^2\epsilon)$ 13
5.1 定义单步错误概率 . . . 13
5.2 如果一直在专家分布上，错误是 $O(T\epsilon)$ . . . 14
5.3 但部署时状态分布会变：关键差别 . . . 14
5.4 最坏情况推导：一次错误导致后面全错 . . . 14
5.5 为什么这个结论有点悲观？ . . . 15

6 解决 Distributional Shift：DAgger 15
6.1 DAgger 的基本想法 . . . 15
6.2 DAgger 算法 . . . 16
6.3 DAgger 为什么能缓解 shift？ . . . 16
6.4 简化版理论结论 . . . 17
6.5 DAgger 的现实代价 . . . 17

7 让 Behavioral Cloning 更好用的技巧 17
7.1 故意加入错误和纠正 . . . 17
7.2 数据增强 . . . 18
7.3 使用非常强大的模型 . . . 18
7.4 多任务学习 . . . 18

8 策略模型为什么不只是简单 MLP：历史、非 Markov 与 Transformer 18
8.1 Non-Markovian Behavior . . . 18
8.2 为什么用 sequence model . . . 19
8.3 Causal Confusion . . . 19

9 Multimodal Behavior：一个状态下多个动作都对怎么办？ 20
9.1 为什么单峰 Gaussian 会失败 . . . 20
9.2 方法一：离散化连续动作 . . . 21
9.3 方法二：Autoregressive Discretization . . . 21
9.4 方法三：更强连续分布 . . . 21

10 Flow Matching 与 Diffusion Policy：从噪声生成动作 22
10.1 Flow Matching 的基本形式 . . . 22
10.2 采样：用 ODE 从噪声走到数据 . . . 23
10.3 把 Flow Matching 用到策略学习 . . . 23
10.4 Action Chunking . . . 24

11 Pre-training：宽数据与窄数据如何结合 **25**
11.1 窄数据与宽数据的矛盾 25
11.2 为什么预训练能帮机器人或策略学习 26

12 Goal-conditioned Behavioral Cloning 与多任务学习 **27**
12.1 普通 BC 与 goal-conditioned BC 27
12.2 从轨迹中自动构造 goal 27
12.3 Goal-conditioned BC 中的两个 distribution shift 28
12.4 Going beyond just imitation 28

13 RL 基础：从 Imitation Learning 过渡到真正的 RL **29**
13.1 为什么不只用监督学习? 29
13.2 RL 的目标函数 30
13.3 RL 与 BC 的本质区别 30
13.4 Learning + Search / Optimization 31

14 和视频/知乎文章主线的对应关系 **32**
14.1 知乎文章题目对应的学习重点 32
14.2 B 站 p=8 视频对应的重点 32

15 公式总表：考前快速复习 **33**

16 易错点总结 **33**

17 新手学习路线建议 **34**

18 练习题 **34**

19 参考资料 **35**

1 先给新手的一句话总览

一句话理解三类学习

- **Supervised Learning**：别人给你标准答案，你学会从输入 x 预测标签 y。
- **Imitation Learning**：别人给你示范动作，你学会在状态/观察 s 或 o 下做同样动作 a。
- **Reinforcement Learning**：没人逐步告诉你正确动作，只告诉你最后好不好，或者每一步给一个 reward，你要自己试、自己优化长期收益。

直观类比：

- 学图像分类：老师给图片和答案，例如“这是一只狗”。这是 supervised learning。
- 学开车：老司机录下一路上每个时刻看到的画面和方向盘角度，你模仿。这是 imitation learning / behavioral cloning。
- 学下棋或学机器人走路：你自己行动，赢了加分、摔倒扣分，从试错中学。这是 reinforcement learning。

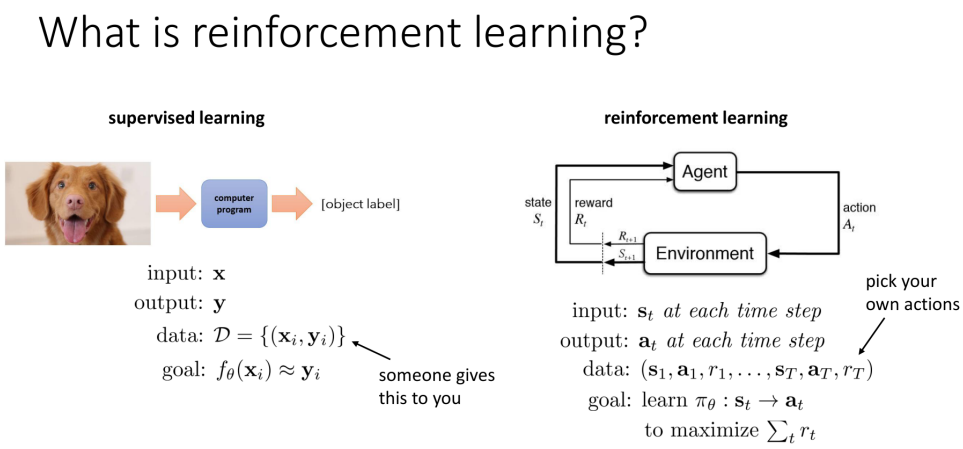
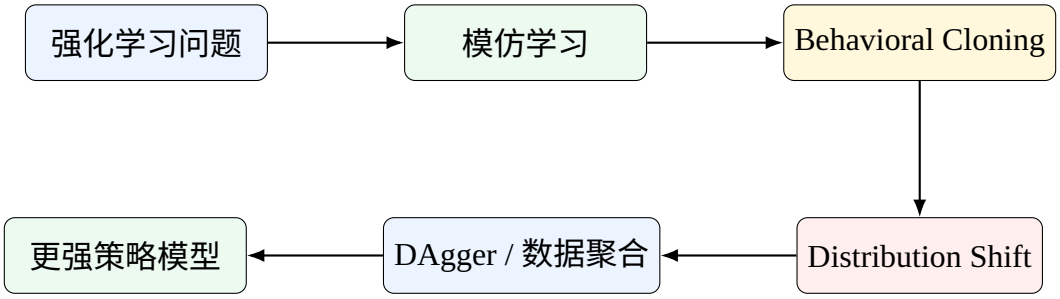


图 1: 课件 Lec 1 第 16 页：监督学习由别人给数据和标签；强化学习需要 agent 自己选择动作，并通过 reward 学习。

1.1 这三节课的主线

这三节课不是一上来就讲 Q-learning 或 Policy Gradient，而是先讲一个更容易理解的入口：**能不能把控制问题当成监督学习来做？**



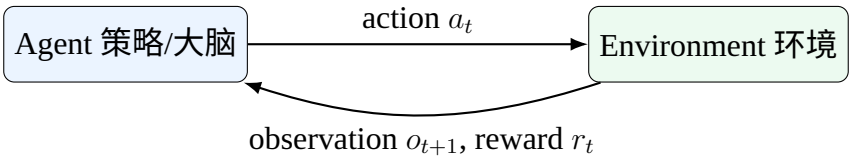
所以本笔记的学习路线是：

1. 先定义 RL 的对象：state、observation、action、reward、policy、trajectory。
2. 再把 imitation learning 写成最大似然估计，即 behavioral cloning。
3. 然后解释为什么 behavioral cloning 会因为 distributional shift 失败。
4. 接着推导为什么错误可能随 horizon 二次增长，即 $O(T^2\epsilon)$。
5. 最后讲修复思路：DAgger、更强模型、数据增强、sequence model、flow matching / diffusion policy、pre-training、多任务学习。

2 基本符号：先把“状态、动作、奖励”说清楚

2.1 Agent 与 Environment

强化学习的核心是一个闭环：



四个最核心概念

英文	常用符号	新手解释
state	s_t	环境真实状态。例如汽车的真实位置、速度、前方车辆位置。
observation	o_t	agent 能看到的信息。例如摄像头图像。它可能不等于完整 state。
action	a_t	agent 做出的动作。例如方向盘角度、油门、机器人关节力矩。
reward	r_t	环境给的反馈分数。例如跑得快加分，撞车扣分。
policy	$\pi(a_t \mid s_t)$ 或 $\pi(a_t \mid o_t)$	策略，即在看到当前信息时选择动作的规则。
trajectory	τ	一整段经历：$s_1, a_1, r_1, s_2, a_2, r_2, \ldots$。

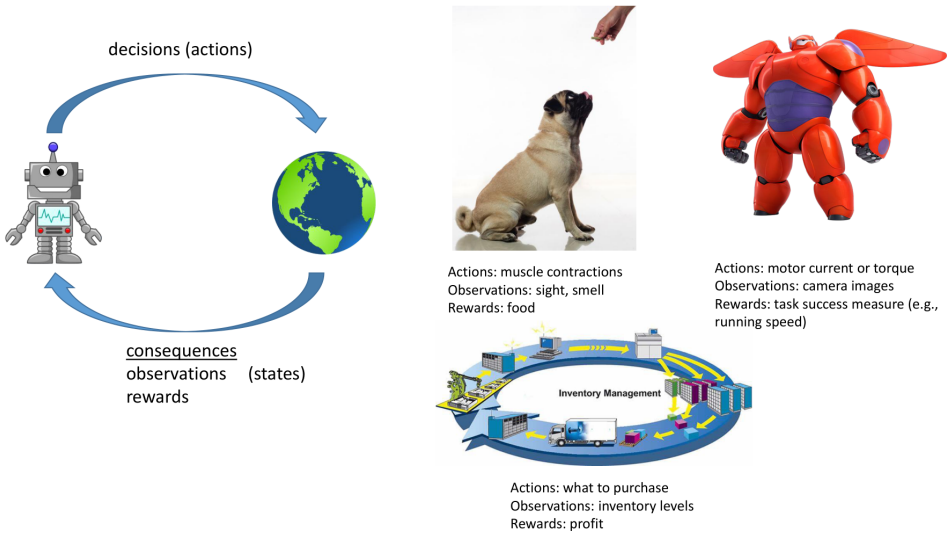


图 2: 课件 Lec 1 第 17 页：不同任务中 actions、observations、rewards 的例子。狗的 action 可以是肌肉收缩，机器人 action 可以是电机力矩，库存管理 action 可以是采购量。

2.2 Fully Observed 与 Partially Observed

Fully Observed Case

如果 agent 能够直接看到环境完整状态，那么

$$o_t = s_t.$$

这时策略可以写成

$$\pi_\theta(a_t \mid s_t).$$

Partially Observed Case

现实中 agent 常常只能看到一部分信息：

$$o_t \sim p(o_t \mid s_t),$$

此时策略写成

$$\pi_\theta(a_t \mid o_t).$$

例如自动驾驶车的摄像头没有直接告诉你“前车真实三维速度”，只给你图像，因此它是 partially observed。

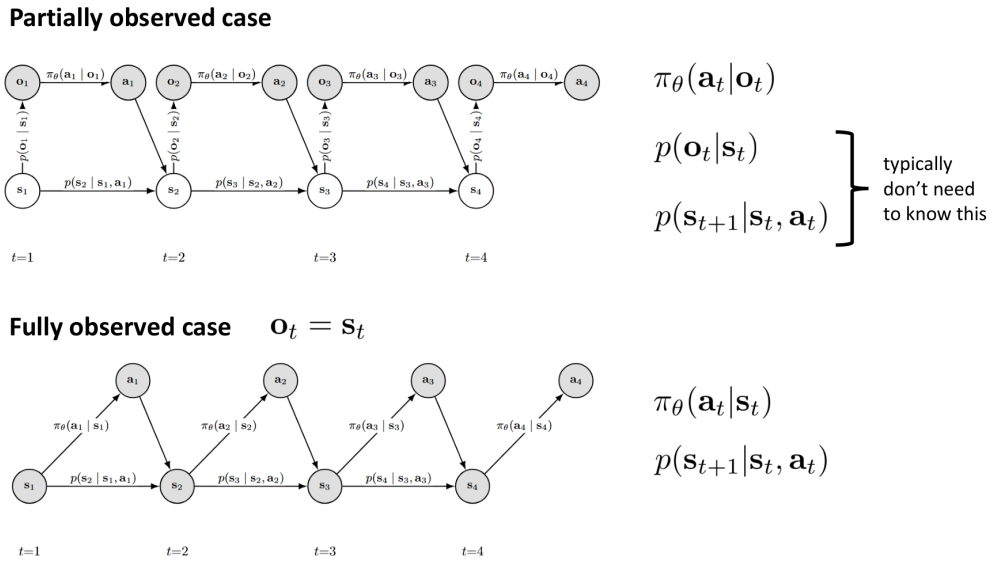


图 3: 课件 Lec 2 第 7 页：fully observed 时 $o_t = s_t$；partially observed 时需要考虑 $p(o_t \mid s_t)$。

2.3 Markov Property：为什么只看当前状态就够？

在理论上，我们常假设环境满足 Markov property：

$$p(s_{t+1} \mid s_1, a_1, \ldots, s_t, a_t) = p(s_{t+1} \mid s_t, a_t).$$

意思是：**只要当前状态 s_t 足够完整，那么未来怎么变化只和当前状态与当前动作有关，不需要把全部历史重新看一遍。**

大白话理解 Markov property

如果 s_t 里面已经包含汽车当前速度、位置、方向、道路情况，那么下一秒车在哪主要由这些当前信息和你现在的油门/刹车/方向盘决定，而不必知道十分钟前你在哪里。

但现实中我们看到的往往是 o_t，而不是完整 s_t。所以有时只看一帧图像不够，需要用历史图像序列：

$$h_t = (o_1, a_1, o_2, a_2, \dots, o_t).$$

这就是后面 sequence model、Transformer policy 的动机。

3 从监督学习到模仿学习：Behavioral Cloning

3.1 监督学习的最大似然写法

监督学习中，数据集是

$$\mathcal{D} = \{(x^{(i)}, y^{(i)})\}_{i=1}^{N}.$$

模型给出条件分布 $p_\theta(y \mid x)$，训练目标是最大化所有标签出现的概率：

$$\theta^* = \arg\max_\theta \sum_{i=1}^{N} \log p_\theta\left(y^{(i)} \mid x^{(i)}\right).$$

这叫 maximum likelihood estimation，简称 MLE。

MLE 的直觉

训练集里真实答案是 $y^{(i)}$。如果模型对真实答案给的概率越大，说明模型越相信正确答案。因此我们最大化 $\log p_\theta(y^{(i)} \mid x^{(i)})$。

对于分类问题，如果模型输出 logits $f_\theta(x) \in \mathbb{R}^K$，softmax 概率为

$$p_\theta(y = k \mid x) = \frac{\exp(f_\theta(x)_k)}{\sum_{j=1}^{K} \exp(f_\theta(x)_j)}.$$

最大化 log likelihood 等价于最小化 cross entropy loss：

$$\mathcal{L}_{\text{CE}}(\theta) = -\sum_{i=1}^{N} \log p_\theta(y^{(i)} \mid x^{(i)}).$$

3.2 把“模仿专家”变成监督学习

模仿学习中，我们没有普通的 (x, y)，而是专家示范轨迹：

$$\mathcal{D} = \left\{\tau^{(i)}\right\}_{i=1}^{N},$$

其中每条轨迹是

$$\tau^{(i)} = \left(o_1^{(i)}, a_1^{(i)}, o_2^{(i)}, a_2^{(i)}, \ldots, o_H^{(i)}, a_H^{(i)}\right).$$

这里 H 是 horizon，也就是一条轨迹的长度。

Behavioral Cloning 的核心想法很简单：**把每个时刻的观察当作输入，把专家动作当作标签。**

于是训练目标为

$$\theta^* = \arg\max_\theta \sum_{i=1}^{N}\sum_{t=1}^{H} \log \pi_\theta\left(a_t^{(i)} \mid o_t^{(i)}\right).$$

等价地，最小化负对数似然：

$$\mathcal{L}_{\mathrm{BC}}(\theta) = -\frac{1}{NH}\sum_{i=1}^{N}\sum_{t=1}^{H} \log \pi_\theta\left(a_t^{(i)} \mid o_t^{(i)}\right).$$

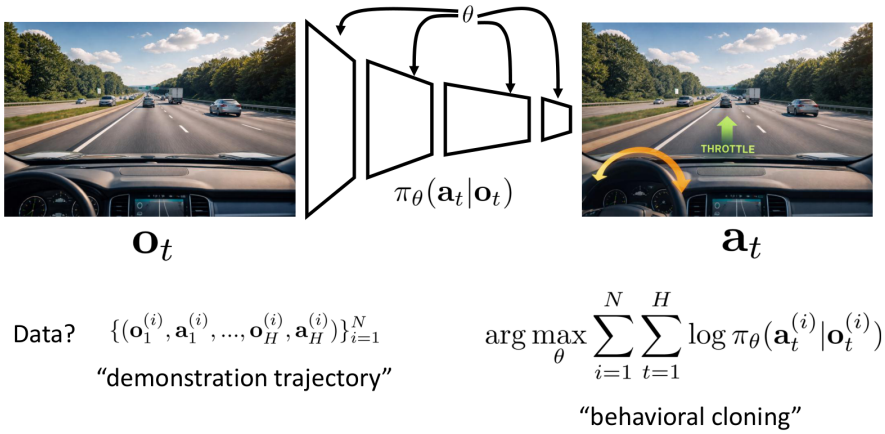


图 4: 课件 Lec 2 第 8 页：demonstration trajectory 与 behavioral cloning 的最大似然目标。

3.3 Behavioral Cloning 算法流程

Behavioral Cloning 算法

1. 收集专家示范数据：让人类专家或已有 controller 运行任务，记录 $\{(o_t, a_t)\}$。
2. 选一个神经网络策略 $\pi_\theta(a \mid o)$，例如 ResNet、ViT、Transformer encoder。
3. 用监督学习训练：让网络在 o_t 下预测专家动作 a_t。
4. 部署时：新观察 o_t 输入网络，采样或输出动作 a_t，再送给环境执行。

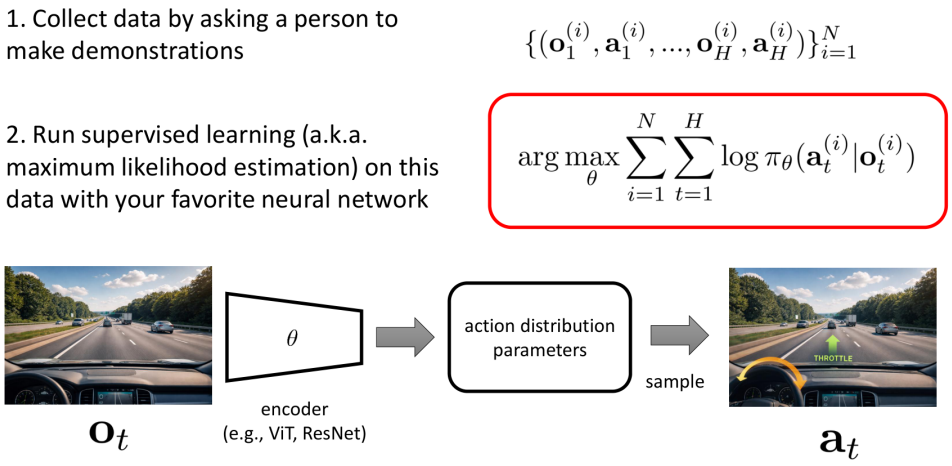


图 5: 课件 Lec 2 第 11 页：Behavioral Cloning 的两步，先收集专家数据，再做最大似然训练。

3.4 离散动作与连续动作

3.4.1 离散动作：输出 logits

例如 Atari 游戏里动作可能是：上、下、左、右、开火。此时动作空间是有限集合

$$\mathcal{A} = \{1, 2, \ldots, K\}.$$

神经网络输出 logits：

$$f_\theta(o) = (f_1(o), \ldots, f_K(o)).$$

策略为 softmax：

$$\pi_\theta(a = k \mid o) = \frac{\exp(f_k(o))}{\sum_{j=1}^{K} \exp(f_j(o))}.$$

训练 loss 是 cross entropy：

$$\mathcal{L}_{\mathrm{BC}}(\theta) = -\mathbb{E}_{(o,a)\sim\mathcal{D}} \log \pi_\theta(a \mid o).$$

3.4.2 连续动作：输出高斯分布参数

例如自动驾驶方向盘角度、机器人关节角速度，它们是连续值。最简单方式是让网络输出 Gaussian 分布：

$$\pi_\theta(a \mid o) = \mathcal{N}(a; \mu_\theta(o), \Sigma_\theta(o)).$$

如果取固定协方差 $\Sigma = \sigma^2 I$，则

$$\log \pi_\theta(a \mid o) = -\frac{1}{2\sigma^2}\|a - \mu_\theta(o)\|_2^2 + C.$$

因此最大化 log likelihood 等价于最小化 MSE：

$$\mathcal{L}_{\mathrm{BC}}(\theta) = \mathbb{E}_{(o,a)\sim\mathcal{D}}\|a - \mu_\theta(o)\|_2^2.$$

注意：MSE 不总是适合连续控制

如果同一个观察 o 下有多个合理动作，例如绕障碍物既可以从左边绕，也可以从右边绕，那么 MSE 可能学出两个动作的平均值。平均动作可能刚好撞到障碍物。这就是 multimodal behavior 的问题。

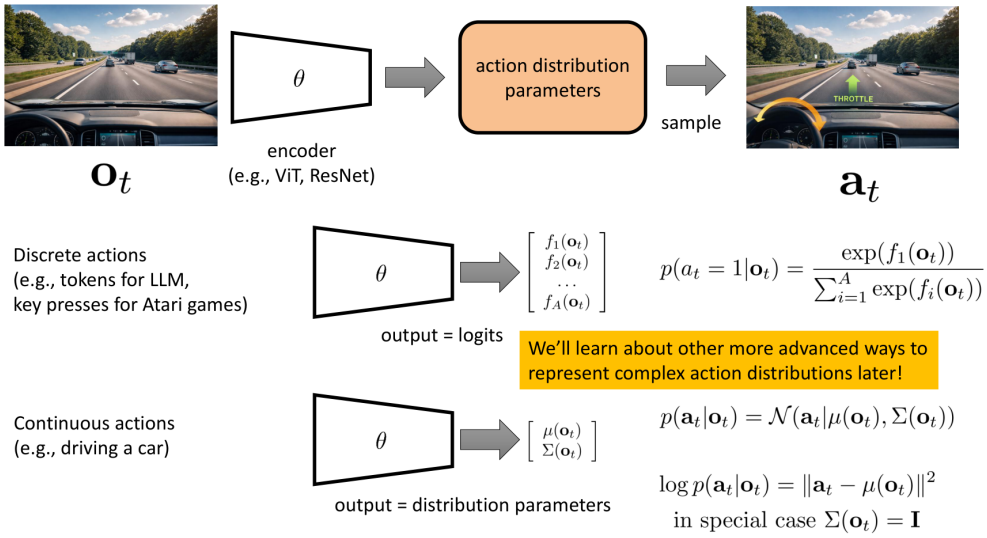


图 6: 课件 Lec 2 第 12 页：离散动作常输出 logits；连续动作常输出分布参数。

4 为什么 Behavioral Cloning 会失败：Distributional Shift

4.1 监督学习默认 i.i.d.，但控制问题不是

监督学习通常默认训练数据和测试数据来自同一个分布：

$$x_{\text{train}} \sim p_{\text{train}}(x), \quad x_{\text{test}} \sim p_{\text{test}}(x), \quad p_{\text{train}}(x) \approx p_{\text{test}}(x).$$

但 behavioral cloning 中，训练状态来自专家策略 $\pi^\star$：

$$o_t \sim d_{\pi^\star}(o_t),$$

测试/部署状态来自我们学到的策略 π_θ：

$$o_t \sim d_{\pi_\theta}(o_t).$$

一旦 π_θ 犯一点小错，车辆/机器人就会进入专家没去过的状态。于是

$$d_{\pi_\theta}(o_t) \neq d_{\pi^\star}(o_t).$$

这就是 distributional shift。

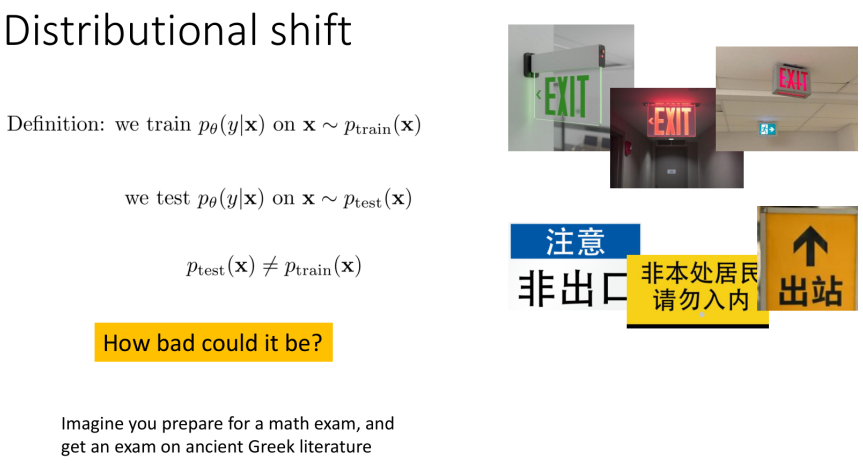


图 7: 课件 Lec 2 第 19 页：distributional shift 的类比——训练时复习数学，考试却考古希腊文学。

4.2 小错误为什么会越滚越大?

自动驾驶例子：专家数据里车总在车道中间，所以模型只学到“在车道中间时怎么开”。部署时模型方向盘偏了一点，车逐渐靠边，进入“偏离车道”的状态。训练集中几乎没有这种状态，所以模型不知道如何纠正，偏差继续变大。

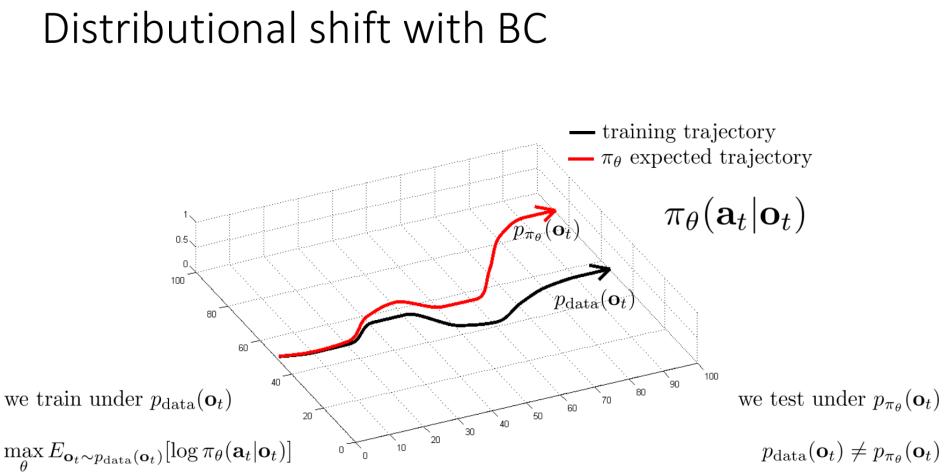


图 8: 课件 Lec 2 第 20 页：behavioral cloning 训练时看到的是 $p_{data}(o_t)$，测试时看到的是自己策略诱导的 $p_{\pi_\theta}(o_t)$。

BC 的核心坑

Behavioral Cloning 的问题不是“不能拟合训练集”。它往往能把训练集拟合得很好。真正的问题是：**部署时它自己造成的数据分布和训练分布不一样。**

5 理论推导：BC 的误差为什么可能是 $O(T^2\epsilon)$

本节是这几节课最重要的公式推导之一。目标是解释：为什么单步误差很小，长期表现仍可能很差。

5.1 定义单步错误概率

假设专家策略是 $\pi^\star$，学到的策略是 π。为了简化，先考虑 fully observed case，即输入是 s_t。

定义 0-1 cost：

$$c(s_t, a_t) = \begin{cases} 0, & a_t = \pi^\star(s_t), \\ 1, & a_t \neq \pi^\star(s_t). \end{cases}$$

它表示“这一时刻有没有做出和专家不同的动作”。

如果状态来自专家分布 $d_{\pi^\star}$，并且动作来自学到的策略 π，则单步错误概率为

$$\epsilon = \mathbb{E}_{s\sim d_{\pi^\star}}\left[\mathbb{P}_{a\sim\pi(a|s)}(a \neq \pi^\star(s))\right].$$

等价写法是

$$\mathbb{E}_{a\sim\pi(a|s)}[c(s,a)] = \sum_a \pi(a \mid s)c(s,a) = \sum_{a\neq\pi^\star(s)} \pi(a \mid s) = 1 - \pi(\pi^\star(s) \mid s).$$

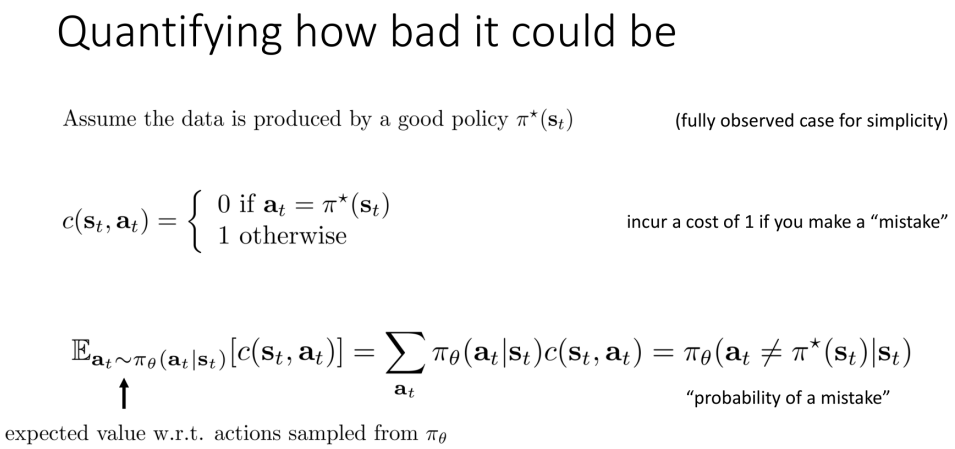


图 9: 课件 Lec 2 第 25 页：将“犯错”定义为 0-1 cost，并把期望 cost 理解为犯错概率。

5.2 如果一直在专家分布上，错误是 $O(T\epsilon)$

如果每一步状态都来自专家分布，那么每步犯错概率不超过 ϵ，总共有 T 步，所以期望错误数大约是

$$\sum_{t=1}^{T} \epsilon = T\epsilon.$$

这就是普通监督学习的乐观情况：错误线性累加。

5.3 但部署时状态分布会变：关键差别

部署时，第 t 步的状态分布来自 d_π^t，它依赖于之前所有动作。总 cost 是

$$J(\pi) = \sum_{t=1}^{T} \mathbb{E}_{s_t \sim d_\pi^t,\, a_t \sim \pi(\cdot|s_t)}[c(s_t, a_t)].$$

这里麻烦在于 d_π^t 不是专家分布。只要前面某一步犯错，后面的状态就可能全部偏到训练集之外。

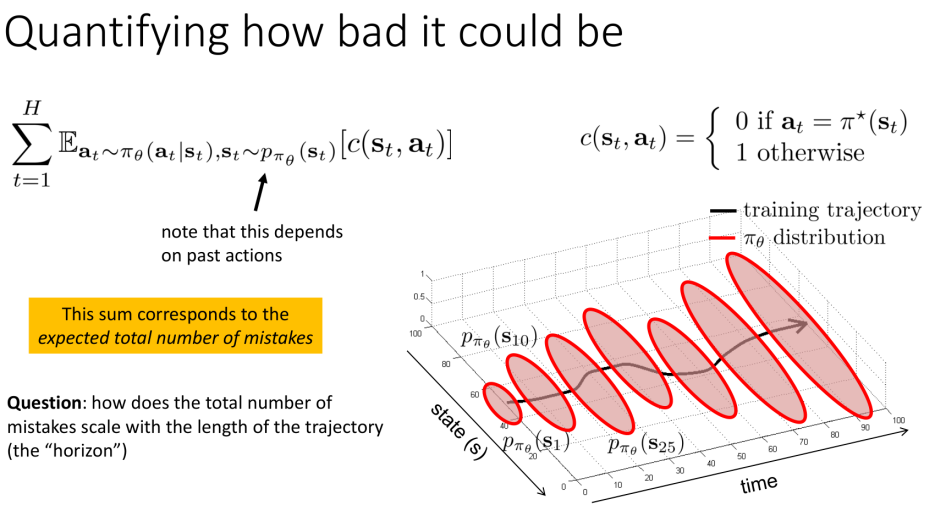


图 10: 课件 Lec 2 第 26 页：总错误数是整个 horizon 上的期望 cost，并且每一步状态分布取决于过去动作。

5.4 最坏情况推导：一次错误导致后面全错

假设最坏情况：只要在前面任意一步犯错，agent 进入灾难状态，之后每一步都错。在第 t 步之前至少犯过一次错的概率可以用 union bound 上界：

$$\mathbb{P}(\text{前}t\text{ 步至少一次错误}) \le \sum_{k=1}^{t} \mathbb{P}(\text{第}k\text{ 步错误}) \le t\epsilon.$$

于是第 t 步处在“错误导致的坏状态”的概率最多是 $t\epsilon$。

总额外 cost 上界为

$$\sum_{t=1}^{T} t\epsilon = \epsilon \frac{T(T+1)}{2} = O(T^2\epsilon).$$

因此 behavioral cloning 的最坏情况性能可以写成

$$J(\pi) \leq J(\pi^\star) + O(T^2\epsilon).$$

重点结论

如果 behavioral cloning 在专家分布上的单步错误率是 ϵ，那么在最坏情况下，长期 cost 可能按

$$O(T^2\epsilon)$$

增长，而不是简单的 $O(T\epsilon)$。这就是 imitation learning 比普通监督学习更难的核心原因。

5.5 为什么这个结论有点悲观?

现实中不一定“一错就永远错”。很多系统能恢复，例如车稍微偏了，仍可能靠方向盘纠正回来。课件也指出这个 worst-case 分析比较 pessimistic。但是这个理论仍然有价值，因为它告诉我们：

- 控制任务不能只看训练集 loss；
- 需要让策略见到自己可能造成的偏离状态；
- 有时含有错误和纠正的数据反而更有帮助。

6 解决 Distributional Shift：DAgger

6.1 DAgger 的基本想法

DAgger = Dataset Aggregation，意思是“数据集聚合”。它的核心做法是：**不要只在专家轨迹上训练，而要让当前策略自己跑，收集它会访问到的状态，再请专家给这些状态标注正确动作。**

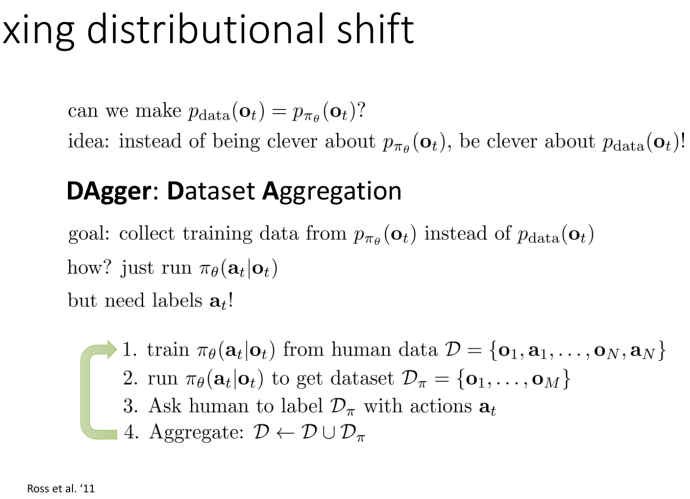


图 11: 课件 Lec 2 第 35 页：DAgger 用于修复 distributional shift。

6.2 DAgger 算法

DAgger 算法步骤

1. 初始化数据集 $\mathcal{D}_0$：收集专家示范。
2. 用 $\mathcal{D}_0$ 训练初始策略 π_1。
3. 对于迭代 $i = 1, 2, \ldots, N$：
   (a) 运行当前策略 π_i，收集它访问到的状态 s 或 observation o。
   (b) 对这些状态询问专家动作 $a^\star = \pi^\star(s)$。
   (c) 把新数据加入数据集：$\mathcal{D}_i = \mathcal{D}_{i-1} \cup \{(s, a^\star)\}$。
   (d) 在聚合数据 $\mathcal{D}_i$ 上重新训练策略 π_{i+1}。

可以把它理解成：

只看专家开车 $\longrightarrow$ 让学生开，老师坐副驾纠正.

6.3 DAgger 为什么能缓解 shift?

Behavioral cloning 训练的是

$$\min_\theta \mathbb{E}_{s\sim d_{\pi^\star}}[-\log \pi_\theta(\pi^\star(s) \mid s)],$$

也就是只在专家状态分布上拟合。

DAgger 更接近训练

$$\min_\theta \mathbb{E}_{s\sim d_{\pi_\theta}}[-\log \pi_\theta(\pi^\star(s) \mid s)],$$

也就是在策略自己会访问到的状态上拟合专家动作。

这就直接对准了部署时会遇到的数据分布。

6.4 简化版理论结论

如果 DAgger 训练出的平均单步错误率为 ϵ_N，则长期 cost 可以做到近似

$$J(\pi) \leq J(\pi^\star) + O(T\epsilon_N),$$

而不是 behavioral cloning 的

$$J(\pi) \leq J(\pi^\star) + O(T^2\epsilon).$$

DAgger 的意义

DAgger 的重点不只是“多收集数据”，而是**收集和当前策略部署分布相匹配的数据**。它把训练分布从专家分布 $d_{\pi^\star}$ 拉向策略自己的分布 d_π。

6.5 DAgger 的现实代价

DAgger 虽然理论漂亮，但现实中有几个问题：

- 每次迭代都要专家标注，专家可能很贵。
- 如果是机器人，当前策略乱跑可能危险。
- 人类专家可能不愿意或不能对所有 visited states 提供动作。
- 对大规模互联网数据或历史日志，无法随时让专家重新标注。

所以后面还要讲其他补救方法：数据增强、更强模型、sequence policy、pre-training、多任务学习等。

7 让 Behavioral Cloning 更好用的技巧

7.1 故意加入错误和纠正

一个反直觉现象：模仿学习有时会因为数据里有“错误和纠正”而更好。

原因是：如果数据全是完美轨迹，模型只知道完美状态下怎么做；如果数据里有人为制造的小偏差，并且专家给出了纠正动作，那么模型就能学习“偏了以后怎么回来”。

开车例子

只看老司机一直在车道中心开，你学不到车偏到边上时怎么办。若数据里有“车稍微偏右，专家向左修正”的样本，你就学会了恢复动作。

7.2 数据增强

自动驾驶论文里常见技巧是使用左、中、右三个摄像头。假设中心摄像头对应正常驾驶动作，左摄像头图像可以被视为“车偏到左边”的观察，此时标签动作应该是向右修正。这样不用真的把车开偏，也能构造纠正数据。

抽象地说，数据增强是在构造

$$(o, a) \quad \rightarrow \quad (\tilde{o}, \tilde{a}),$$

其中 $\tilde{o}$ 是模拟偏离状态，$\tilde{a}$ 是纠正动作。

7.3 使用非常强大的模型

如果模型足够强，单步错误率 ϵ 很小，那么即使 $O(T^2\epsilon)$ 看起来可怕，实际错误也可能可控。这就是为什么大模型、预训练模型、视觉基础模型会让 imitation learning 更实用。

但强模型不是万能的：如果训练数据从来没有覆盖某些状态，再强模型也可能不知道怎么恢复。

7.4 多任务学习

如果同时学习很多任务，模型会看到更多状态、更多动作模式、更多恢复方式。多任务数据可以扩大状态覆盖范围，从而缓解 narrow expert data 的问题。

8 策略模型为什么不只是简单 MLP：历史、非 Markov 与 Transformer

8.1 Non-Markovian Behavior

课件 Lec 3 提到 imitation learning 失败的一个原因是 non-Markovian behavior。

如果人类行为依赖历史，而模型只看当前 observation，就可能学不好。例如：

- 同一帧道路图像可能对应“刚刚从左边绕过障碍物”和“刚刚从右边绕过障碍物”；
- 机器人手臂当前画面一样，但之前抓取方向不同，后续动作不同；
- 对话模型当前一句话一样，但历史上下文不同，回答应不同。

因此策略应该写成

$$\pi_\theta(a_t \mid h_t),$$

其中历史为

$$h_t = (o_1, a_1, o_2, a_2, \ldots, o_t).$$

8.2 为什么用 sequence model

如果把所有历史帧拼接起来输入普通网络，历史长度变化时参数数量难处理。Sequence model 使用共享权重，可以处理变长序列。

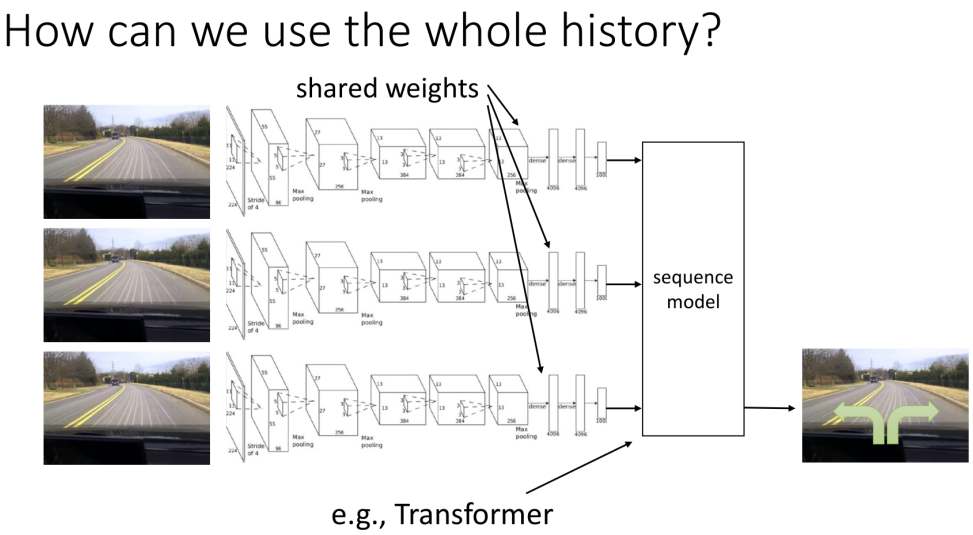


图 12: 课件 Lec 3 第 7 页：使用 sequence model，例如 Transformer，用共享权重处理历史。

Transformer policy 的形式可以写成

$$z_{1:t} = \text{Transformer}_\theta(e(o_1), e(a_1), \ldots, e(o_t)),$$

然后用最后一个 hidden state 预测动作：

$$\pi_\theta(a_t \mid h_t) = \pi_\theta(a_t \mid z_t).$$

8.3 Causal Confusion

Causal confusion 指模型学到了相关但不是因果的线索。比如驾驶时，刹车灯亮与刹车动作相关，但真正原因可能是前方行人。如果模型只盯着刹车灯，而忽略行人，就可能在新环境中失败。

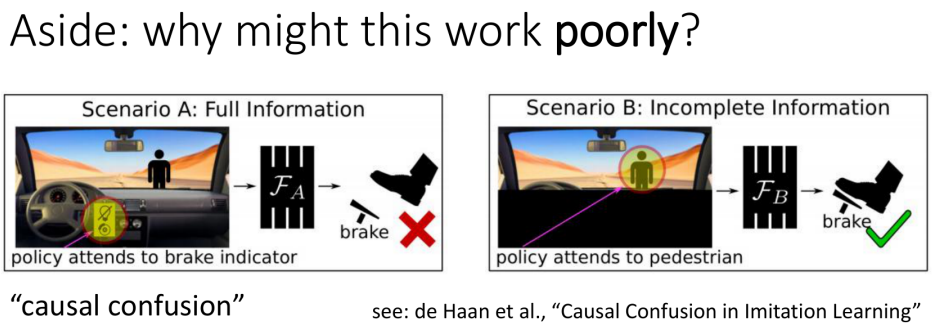


图 13: 课件 Lec 3 第 8 页：causal confusion 例子，策略可能错误关注 brake indicator，而不是真正需要关注的 pedestrian。

历史信息不一定解决因果混淆

加入历史可以缓解部分 partial observability，但不保证学到真正因果因素。如果历史中某些伪相关信号更容易预测动作，模型仍可能依赖它们。

9 Multimodal Behavior：一个状态下多个动作都对怎么办？

9.1 为什么单峰 Gaussian 会失败

考虑一个障碍物在正前方，专家可以从左边绕，也可以从右边绕。若数据集中两种选择都有，则同一个 observation 下动作分布是双峰的：

$$p(a \mid o) = 0.5\, p_{\text{left}}(a \mid o) + 0.5\, p_{\text{right}}(a \mid o).$$

如果用单个 Gaussian 或 MSE 学习，模型可能输出平均动作：

$$\bar{a} = \frac{a_{\text{left}} + a_{\text{right}}}{2}.$$

但平均动作可能是“直走撞上障碍物”。

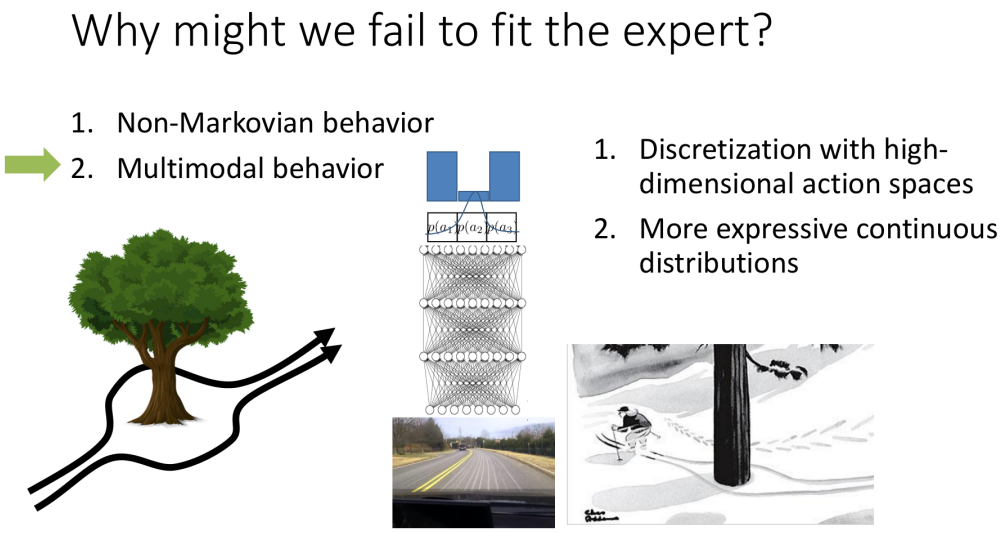


图 14: 课件 Lec 3 第 9 页：专家行为可能是 multimodal。解决方向包括高维动作离散化、更有表达力的连续分布。

9.2 方法一：离散化连续动作

如果动作是一维，比如方向盘角度 $a \in [-1, 1]$，可以把它切成 K 个 bins：

$$[-1, 1] \to \{1, 2, \ldots, K\}.$$

然后当分类做：

$$\pi_\theta(a = k \mid o) = \text{softmax}(f_\theta(o))_k.$$

但如果动作是 d 维，每维 K 个 bins，那么总类别数是

$$K^d.$$

当 d 很大时不可行。

9.3 方法二：Autoregressive Discretization

把高维动作拆成一个维度一个维度预测：

$$p(a \mid o) = \prod_{j=1}^{d} p(a_j \mid o, a_1, \ldots, a_{j-1}).$$

这样每次只预测一维动作的离散类别，避免 K^d 爆炸。

9.4 方法三：更强连续分布

可以使用更有表达力的分布模型：

- Mixture Density Network：多个 Gaussian 混合。
- Conditional VAE：用隐变量 z 表示不同 action mode。
- Normalizing Flow：把简单噪声通过可逆变换变成复杂动作分布。
- Diffusion / Flow Matching：从噪声逐步生成动作。

10 Flow Matching 与 Diffusion Policy：从噪声生成动作

这一部分是 Lec 3 中较前沿的内容。新手可以先抓住一句话：**不要让策略直接输出一个动作，而是让策略从随机噪声出发，逐步“流动”到一个合理动作。**

10.1 Flow Matching 的基本形式

设真实数据样本为

$$x_1 \sim p_{\text{data}}(x),$$

噪声样本为

$$x_0 \sim p_0(x) = \mathcal{N}(0, I).$$

定义从噪声到数据的线性插值：

$$x_t = (1-t)x_0 + tx_1, \quad t \in [0,1].$$

对 t 求导：

$$\frac{dx_t}{dt} = x_1 - x_0.$$

这个导数就是 target velocity。训练一个网络 $v_\theta(x_t, t)$ 去预测这个速度：

$$\mathcal{L}_{\text{FM}}(\theta) = \mathbb{E}_{x_0 \sim \mathcal{N}(0,I),\, x_1 \sim p_{\text{data}},\, t \sim U(0,1)} \left\| v_\theta(x_t, t) - (x_1 - x_0) \right\|_2^2 .$$

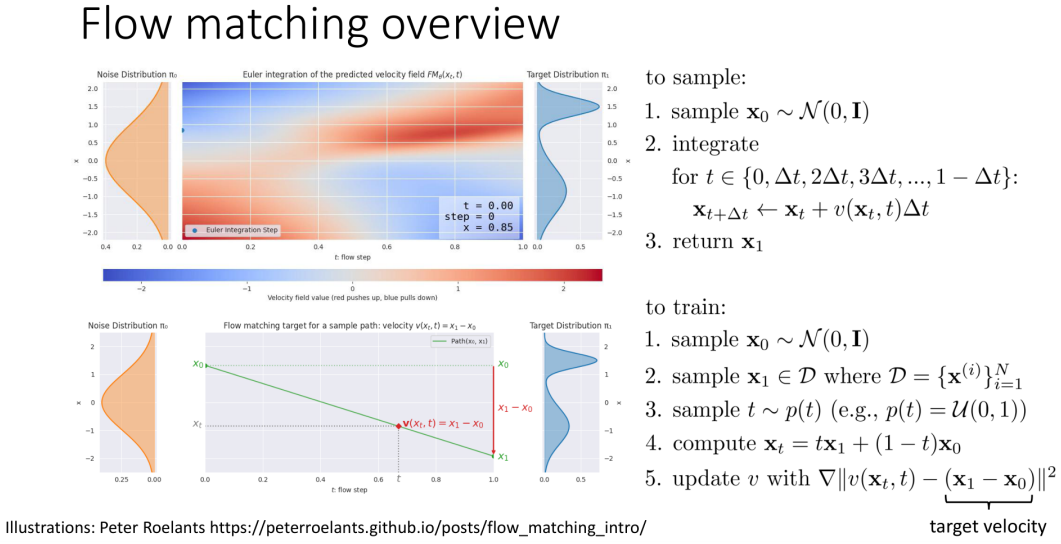


图 15: 课件 Lec 3 第 14 页：Flow Matching 训练时采样噪声 x_0、数据 x_1 和时间 t，学习 target velocity；采样时从噪声积分到数据。

10.2 采样：用 ODE 从噪声走到数据

训练好 v_θ 后，生成样本时先采样

$$x_0 \sim \mathcal{N}(0, I),$$

然后解常微分方程

$$\frac{dx_t}{dt} = v_\theta(x_t, t), \quad t : 0 \to 1.$$

用 Euler 方法近似：

$$x_{t+\Delta t} = x_t + v_\theta(x_t, t)\Delta t.$$

最后得到 x_1，作为生成样本。

10.3 把 Flow Matching 用到策略学习

在 imitation learning 中，数据不是普通图片，而是专家动作。设动作 chunk 为

$$a^\star_{t:t+K} = \left(a^\star_t, a^\star_{t+1}, \ldots, a^\star_{t+K}\right).$$

把它当作 flow matching 的数据样本 x_1：

$$x_1 = a^\star_{t:t+K}.$$

采样噪声动作：

$$x_0 = a_0 \sim \mathcal{N}(0, I).$$

时间 $\tau \sim U(0,1)$，构造加噪动作：

$$a_\tau = (1-\tau)a_0 + \tau a^\star_{t:t+K}.$$

训练条件速度场：

$$v_\theta(o_t, a_\tau, \tau) \approx a^\star_{t:t+K} - a_0.$$

loss 为

$$\mathcal{L}_{\text{policy-FM}}(\theta) = \mathbb{E}\left[\left\| v_\theta(o_t, a_\tau, \tau) - \left(a^\star_{t:t+K} - a_0\right)\right\|_2^2\right].$$

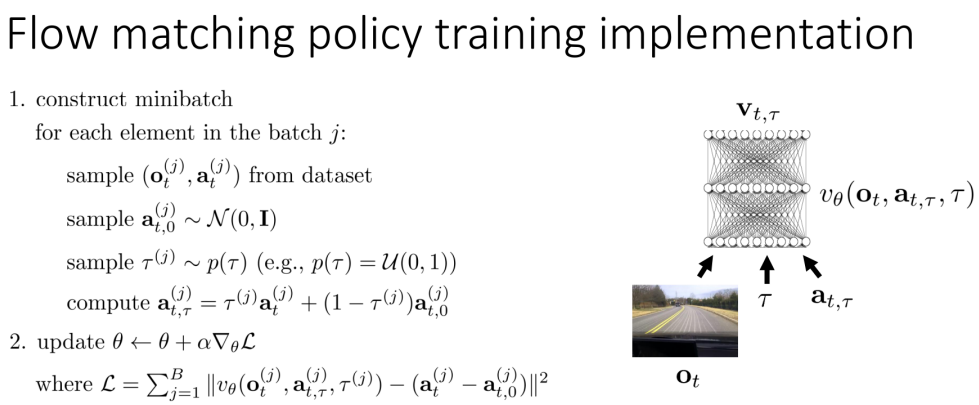


图 16: 课件 Lec 3 第 15 页：Flow matching policy training implementation。模型输入 observation、noisy action 和时间，输出 velocity。

10.4 Action Chunking

普通 policy 是每一步预测一个动作：

$$a_t \sim \pi_\theta(a_t \mid o_t),$$

执行 a_t，观察 o_{t+1}，重复。

Action chunking 一次预测未来 K 个动作：

$$a_{t:t+K} \sim \pi_\theta(a_{t:t+K} \mid o_t),$$

然后连续执行这段动作中的一部分或全部。

Action chunking

A small detail that helps quite a lot

standard policy:

sample $\mathbf{a}_t \sim \pi_\theta(\mathbf{a}_t|\mathbf{o}_t)$

execute $\mathbf{a}_t$ in the environment

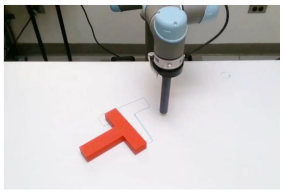
observe $\mathbf{o}_{t+1}$, repeat

action chunked policy:

sample $\mathbf{a}_{t:t+K} \sim \pi_\theta(\mathbf{a}_{t:t+K}|\mathbf{o}_t)$

execute $\mathbf{a}_t, \mathbf{a}_{t+1}, ..., \mathbf{a}_{t+K}$ in the environment

observe $\mathbf{o}_{t+K+1}$, repeat



Chi et al. Diffusion policy, 2024

图 17: 课件 Lec 3 第 16 页：action chunking 是一个“小细节”，但在机器人模仿学习中很有帮助。

为什么 action chunking 有帮助?

机器人动作通常有连续性。比如拿杯子不是每 0.02 秒重新独立决定一次，而是一小段连续动作。一次生成 action chunk 可以让动作更平滑、更有计划性，也更适合 diffusion / flow matching 这类生成模型。

11 Pre-training：宽数据与窄数据如何结合

11.1 窄数据与宽数据的矛盾

课件 Lec 3 提到：

- **Good but narrow data**：高质量专家数据，动作很好，但覆盖状态少。
- **Bad but broad data**：数据范围很广，覆盖很多状态，但动作质量参差不齐。

模仿学习希望二者兼得：既看到很多状态，又学到高质量动作。

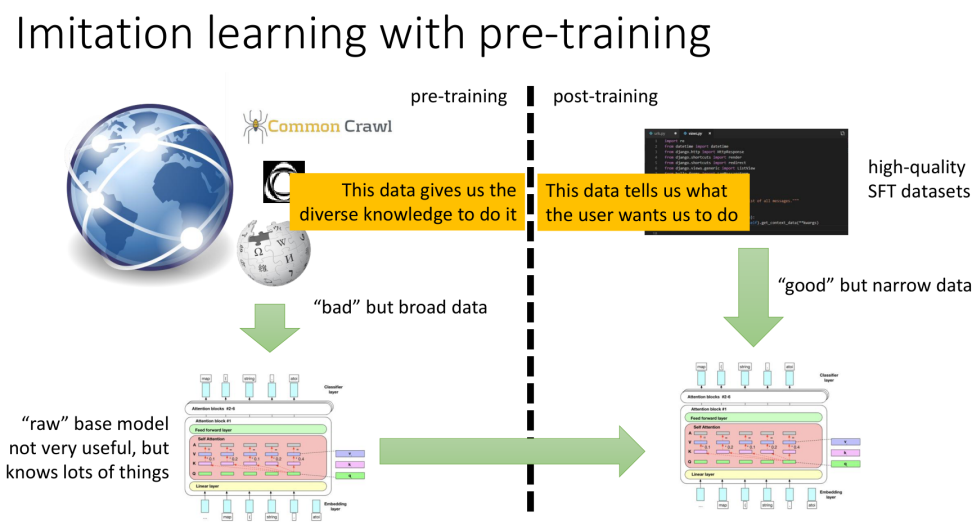


图 18: 课件 Lec 3 第 22 页：pre-training 提供广泛知识，post-training / SFT 数据告诉模型用户真正希望它怎么做。

11.2 为什么预训练能帮机器人或策略学习

可以把策略训练分成两阶段：

$$\text{Pre-training on broad data} \quad \rightarrow \quad \text{Post-training on high-quality task data.}$$

预训练让模型学到：

- 视觉世界的通用表示；
- 物体、手、工具、空间关系；
- 多种 embodiment 的动作模式；
- 从错误状态恢复的可能方式。

后训练让模型学到：

- 这个具体任务应该怎么做；
- 什么动作是高质量的；
- 任务成功标准和用户偏好。

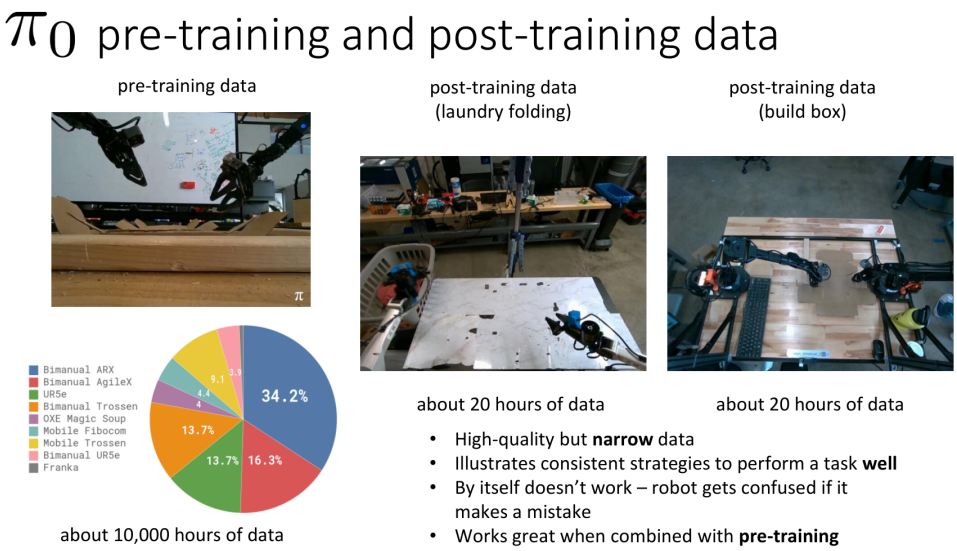


图 19: 课件 Lec 3 第 23 页：大量预训练数据和少量高质量 post-training 数据结合，可以让策略既有广覆盖，又有好动作。

12 Goal-conditioned Behavioral Cloning 与多任务学习

12.1 普通 BC 与 goal-conditioned BC

普通 BC 学的是

$$\pi_\theta(a_t \mid o_t).$$

Goal-conditioned BC 多给一个目标 g：

$$\pi_\theta(a_t \mid o_t, g).$$

目标 g 可以是目标图像、目标位置、自然语言指令或未来状态。

大白话解释

普通 BC 像是在说："看到这个画面，你下一步怎么做?" Goal-conditioned BC 像是在说："看到这个画面，并且你的目标是到那里，你下一步怎么做?"

12.2 从轨迹中自动构造 goal

如果有一条轨迹

$$(o_1, a_1, o_2, a_2, \ldots, o_H),$$

可以选未来某一时刻 $k > t$ 的观察作为 goal：

$$g = o_k.$$

然后训练

$$\max_{\theta} \sum_{t<k} \log \pi_\theta(a_t \mid o_t, g = o_k).$$

这叫 hindsight relabeling 的思想：已经发生的未来状态可以当作“当时的目标”。

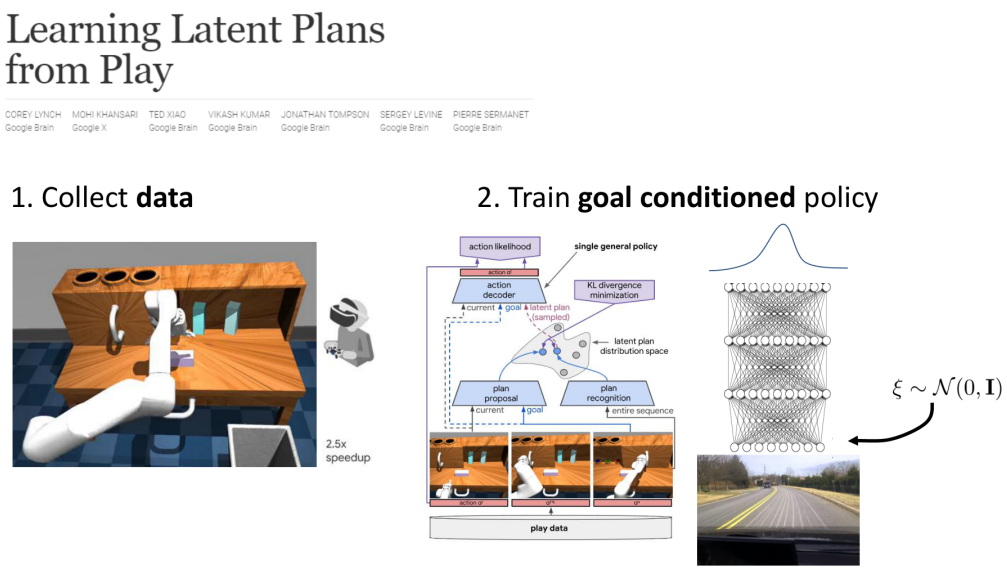


图 20: 课件 Lec 3 第 28 页：收集数据，然后训练 goal-conditioned policy。

12.3 Goal-conditioned BC 中的两个 distribution shift

课件提到 goal-conditioned BC 里会有两处 distribution shift：

1. **状态分布 shift**：和普通 BC 一样，训练时是数据策略访问的状态，测试时是学到的策略访问的状态。
2. **目标分布/目标可达性 shift**：训练目标通常来自轨迹中真实到达的未来状态；测试时用户给的目标可能更远、更难、或者不在训练分布内。

   因此 goal-conditioned policy 既要学会动作，也要有足够广的目标覆盖。

12.4 Going beyond just imitation

Lec 3 最后给出一种从随机策略开始的想法：

1. 从 random policy 开始。
2. 随机目标或随机探索，收集轨迹。
3. 把实际达到的状态当作目标，把这条轨迹当作 demonstration。
4. 用这些 hindsight demonstrations 改进策略。

5. 重复。

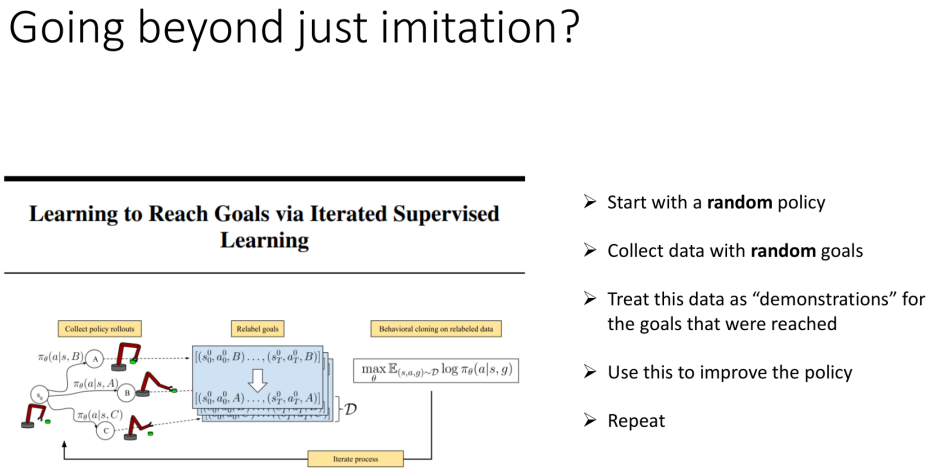


图 21: 课件 Lec 3 第 30 页：通过随机目标收集数据，再把达到的目标当作示范，反复改进策略。

这已经开始接近 off-policy RL 和 goal-conditioned RL 的思想。

13 RL 基础：从 Imitation Learning 过渡到真正的 RL

13.1 为什么不只用监督学习?

监督学习擅长 “从数据中学习模式”，但它通常不会主动优化超过数据的目标。课件 Lec 1 强调：data-driven AI 侧重从数据中学世界，RL 侧重优化目标并可能产生 emergent behavior。

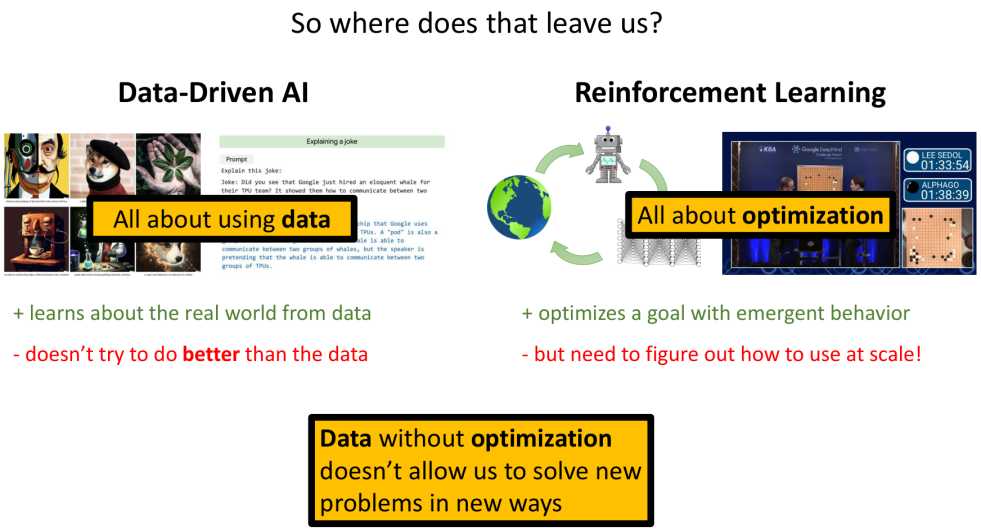


图 22: 课件 Lec 1 第 29 页：Data-driven AI 与 Reinforcement Learning 的互补关系。

13.2 RL 的目标函数

在 RL 中，一条轨迹是

$$\tau = (s_1, a_1, r_1, s_2, a_2, r_2, \ldots, s_T, a_T, r_T).$$

策略 π_θ 诱导轨迹分布

$$p_\theta(\tau) = p(s_1) \prod_{t=1}^{T} \pi_\theta(a_t \mid s_t) p(s_{t+1} \mid s_t, a_t).$$

RL 的目标是最大化期望累计回报：

$$J(\theta) = \mathbb{E}_{\tau \sim p_\theta(\tau)} \left[\sum_{t=1}^{T} r(s_t, a_t) \right].$$

如果使用 discount factor $\gamma \in [0, 1]$，则

$$J(\theta) = \mathbb{E}_{\tau \sim p_\theta(\tau)} \left[\sum_{t=1}^{T} \gamma^{t-1} r(s_t, a_t) \right].$$

13.3 RL 与 BC 的本质区别

对比项	Behavioral Cloning	Reinforcement Learning
监督信号	专家动作 $a^\star$	reward r 或 cost c
训练目标	拟合专家动作	最大化长期回报

数据来源	专家示范数据	agent 与环境交互
核心难点	distributional shift	exploration、credit assignment、sample efficiency
能否超越专家	通常较难	理论上可以通过试错超越已有数据
典型公式	$\max_\theta \sum \log \pi_\theta(a^\star \mid o)$	$\max_\theta \mathbb{E}_{\tau\sim\pi_\theta} \sum r_t$

13.4 Learning + Search / Optimization

Lec 1 中使用 Sutton 的“Bitter Lesson”思路强调：可扩展的方法往往是 learning 与 search。Deep RL 可以理解为二者结合：

- Deep learning：从大规模复杂数据中学习表示；
- RL / optimization：通过交互和优化寻找高回报行为。

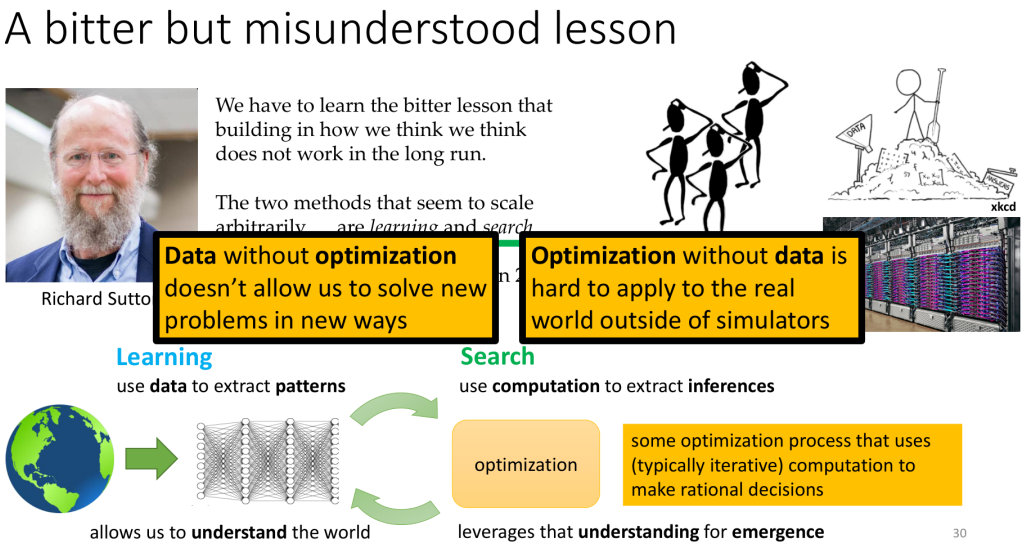


图 23: 课件 Lec 1 第 30 页：Learning 用数据提取模式，Search/Optimization 用计算提取决策。

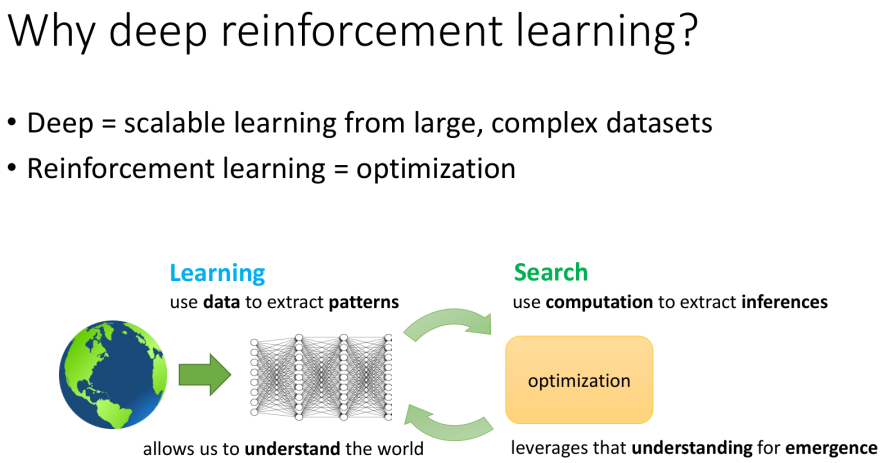


图 24: 课件 Lec 1 第 37 页：Deep = scalable learning from large complex datasets；RL = optimization。

14 和视频/知乎文章主线的对应关系

14.1 知乎文章题目对应的学习重点

用户给出的知乎链接标题可见为“强化学习 *CS285* 笔记【一】*Behaviour Clone*（为什么要用强化学习）”。从标题看，它对应的主题正是本笔记前半部分：

- 为什么控制/决策问题不能简单当监督学习；
- behavioral cloning 如何把模仿学习转成最大似然；
- 为什么 BC 会因 distributional shift 失败；
- 为什么需要 RL 或 DAgger 等交互式方法。

14.2 B 站 p=8 视频对应的重点

用户给出的 B 站链接搜索信息显示该视频集是 CS285 中英字幕，p8 对应“CS 285: Lecture 2, Imitation Learning, Part 5”。这部分通常位于 imitation learning 讲解后段，重点是如何修复 behavioral cloning 的问题，尤其是 DAgger、数据增强和让模型见到纠正状态。

因此，如果按视频学习，可以这样对应：

材料	对应本笔记章节

Lec 1 Introduction	第 1、2、10 节：RL 基本概念、为什么需要 RL、learning + optimization
Lec 2 Behavioral Cloning	第 3、4、5、6 节：BC、distribution shift、$O(T^2\epsilon)$、DAgger
Lec 3 Behavioral Cloning Part 2	第 7、8、9 节：sequence model、multimodal actions、flow matching、pre-training、多任务
B 站 p=8	第 6 节和第 7 节：修复 BC 的 practical methods
知乎文章	第 3-5 节：从监督学习视角理解为什么需要 RL / BC 的局限

15 公式总表：考前快速复习

概念	公式	含义
Supervised MLE	$\theta^* = \arg\max_\theta \sum_i \log p_\theta(y^{(i)} \mid x^{(i)})$	拟合标签
BC 目标	$\theta^* = \arg\max_\theta \sum_{i,t} \log \pi_\theta(a_t^{(i)} \mid o_t^{(i)})$	模仿专家动作
BC loss	$\mathcal{L}_{BC} = -\mathbb{E}_{(o,a)\sim\mathcal{D}} \log \pi_\theta(a \mid o)$	负对数似然
连续 Gaussian 策略	$\pi_\theta(a \mid o) = \mathcal{N}(a; \mu_\theta(o), \Sigma)$	输出动作分布
MSE 等价	$-\log \pi_\theta(a \mid o) \propto \|a - \mu_\theta(o)\|^2$	固定协方差时
单步错误率	$\epsilon = \mathbb{E}_{s\sim d_{\pi^\star}} \mathbb{P}_{a\sim\pi}(a \neq \pi^\star(s))$	在专家分布上犯错概率
BC 最坏长期误差	$J(\pi) \leq J(\pi^\star) + O(T^2\epsilon)$	错误可能二次累积
DAgger 改进	$J(\pi) \leq J(\pi^\star) + O(T\epsilon_N)$	在自己状态分布上学习
RL 目标	$J(\theta) = \mathbb{E}_{\tau\sim p_\theta(\tau)} \sum_t \gamma^{t-1} r_t$	最大化长期回报
Flow interpolation	$x_t = (1-t)x_0 + tx_1$	从噪声到数据
Flow target velocity	$u_t = x_1 - x_0$	线性路径速度
Flow matching loss	$\mathbb{E}\|v_\theta(x_t, t) - (x_1 - x_0)\|^2$	学习速度场
Autoregressive action	$p(a \mid o) = \prod_{j=1}^d p(a_j \mid o, a_{<j})$	高维动作逐维建模
Goal-conditioned BC	$\max_\theta \sum_{t<k} \log \pi_\theta(a_t \mid o_t, g = o_k)$	用目标条件控制

16 易错点总结

易错点 1：以为 BC 就是普通监督学习，没有额外问题

错。BC 的训练形式像监督学习，但部署时动作会影响未来状态，所以训练分布和测试分布不再独立同分布。

易错点 2：只看训练 loss 判断策略好坏

错。BC 的训练 loss 很低，也可能部署失败。必须看 rollout 表现，因为策略执行会改变状态分布。

易错点 3：连续动作一律用 MSE

错。若专家动作是 multimodal，MSE 会学到平均动作，平均动作可能不是好动作。

易错点 4：以为 DAgger 只是加数据

错。DAgger 的关键是加“当前策略会访问到的状态”的专家标签，而不是随便多加数据。

易错点 5：以为加入历史一定解决问题

不一定。历史可以缓解 partial observability，但 causal confusion 仍可能存在。

17 新手学习路线建议

1. 先背熟基本符号：$s_t, o_t, a_t, r_t, \pi_\theta, \tau, H, T$。
2. 手推一遍 BC 的最大似然目标：从 supervised MLE 到 $\sum_{i,t} \log \pi_\theta(a_t^{(i)} \mid o_t^{(i)})$。
3. 画图理解 distribution shift：训练时专家状态，测试时自己策略状态。
4. 手推 $O(T^2\epsilon)$：关键是 union bound 和“前面错误影响后面状态”。
5. 用一句话记住 DAgger：让学生自己开，老师标注学生会遇到的状态。
6. 再看 Lec 3：为什么需要 Transformer、扩散模型、预训练、多任务。

最重要的三句话

1. Behavioral Cloning = 把专家动作当标签的监督学习。
2. Behavioral Cloning 的核心问题 = 部署时自己导致 distributional shift。
3. DAgger 的核心改进 = 训练数据要覆盖当前策略实际会遇到的状态。

18 练习题

练习 1：从 MLE 推出 BC loss

给定示范数据 $\mathcal{D} = \{(o_t^{(i)}, a_t^{(i)})\}_{i,t}$，写出最大似然目标，并说明为什么最小化 NLL 等价于 behavioral cloning。

参考答案

最大似然：

$$\max_\theta \prod_{i,t} \pi_\theta(a_t^{(i)} \mid o_t^{(i)}).$$

取 log：

$$\max_\theta \sum_{i,t} \log \pi_\theta(a_t^{(i)} \mid o_t^{(i)}).$$

等价最小化：

$$\min_\theta -\sum_{i,t} \log \pi_\theta(a_t^{(i)} \mid o_t^{(i)}).$$

这就是 BC 的 NLL loss。

练习 2：为什么 BC 的错误可能是 $O(T^2\epsilon)$?

假设每一步在专家分布上的错误概率不超过 ϵ，并且一旦某一步错误，之后状态都可能变坏。证明总 cost 是 $O(T^2\epsilon)$。

参考答案

第 t 步之前至少一次错误的概率由 union bound：

$$\mathbb{P}(\text{前}t\text{ 步有错误}) \le t\epsilon.$$

每个时刻的坏状态概率最多 $t\epsilon$，总 cost：

$$\sum_{t=1}^{T} t\epsilon = \epsilon \frac{T(T+1)}{2} = O(T^2\epsilon).$$

练习 3：为什么 DAgger 能缓解 distribution shift?

参考答案

BC 在专家状态分布 $d_{\pi^\star}$ 上训练，而测试时状态来自 d_π。DAgger 让当前策略 π_i 自己运行，收集 d_{π_i} 下的状态，并请专家标注动作。因此训练分布逐渐接近部署分布，从而缓解 distribution shift。

19 参考资料

1. Sergey Levine, UC Berkeley CS 185/285: Deep Reinforcement Learning, Lecture 1: Introduction, 用户上传课件 `lec-1.pdf`。

2. Sergey Levine, UC Berkeley CS 185/285: Deep Reinforcement Learning, Lecture 2: Behavioral Cloning, 用户上传课件 `lec-2.pdf`。

3. Sergey Levine, UC Berkeley CS 185/285: Deep Reinforcement Learning, Lecture 3: Behavioral Cloning Part 2, 用户上传课件 `lec-3.pdf`。

4. UC Berkeley CS 185/285 官方课程网站：CS285 Deep Reinforcement Learning Course Website

5. Bilibili 视频集：【深度强化学习 *CS285 2023*】伯克利—中英字幕，用户提供链接；p=8 对应 Lecture 2 Imitation Learning Part 5。

6. 知乎文章：强化学习 *CS285* 笔记【一】*Behaviour Clone*（为什么要用强化学习），用户提供链接；网页抓取存在 403 限制，本文仅用其可见题目与课程主线进行对照。

7. Ross, Gordon, and Bagnell. *A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning*. AISTATS 2011.

8. Chi et al. *Diffusion Policy: Visuomotor Policy Learning via Action Diffusion*. 2023/2024.